Федеральное государственное автономное образовательное учреждение высшего образования «Национальный исследовательский университет ИТМО»

Факультет программной инженерии и компьютерной техники
Направление подготовки: 09.03.04 – Программная инженерия, Системное и прикладное программное обеспечение

Дисциплина: Моделирование

Учебно-исследовательская работа №1

Обработка результатов измерений: статистический анализ числовой последовательности

Вариант: 205

Выполнил:
Карнажицкий Максим Романович
Группа: P3311

Проверил:
Тропченко А. А.

г. Санкт-Петербург, 2026

Содержание

Цель работы 2
Исходный код 2
1. Оценка статистических значений выборки 3
2. График значений заданной числовой последовательности 6
3. Автокорреляционный анализ 7
4. Гистограмма распределения частот 9
5. Выбор аппроксимирующего закона распределения 11
6. Формирование последовательности по аппроксимирующему закону . 12
7. Сравнение исходной и сгенерированной последовательностей 13
   7.1. Сравнение гистограммы и теоретической плотности 13
   7.2. Сравнение числовых характеристик 14
   7.3. Сравнение коэффициентов автокорреляции 15
   7.4. Корреляционный анализ последовательностей 15
8. Вывод 17

Цель работы

Изучение методов обработки и статистического анализа результатов измерений на примере заданной числовой последовательности путем оценки числовых моментов и выявления свойств последовательности на основе корреляционного анализа, а также аппроксимация закона распределения заданной последовательности по двум числовым моментам случайной величины.

Исходный код

Исходный код вычислений лежит в публичном Github-репозитории: https://github.com/xtern0o/modeling_labs/tree/main/lab1

Структура файлов:

```
+ main.py       # основной файл, в котором происходят все вычисления
|               # по ходу лабораторной
+ data.py       # парсинг строкового результата копирования
|               # последовательности варианта 205 из Excel
+ graphtools.py # все функции рисования графиков
+ out/*.svg     # результаты рисования графиков
```

1. Оценка статистических значений выборки

Были рассчитаны основные статистические характеристики для выборок объемом 10, 20, 50, 100, 200 и 300 значений.

Оценка мат. ожидания вычислялась как выборочное среднее:

$$\overline{x}_n = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Исправленная выборочная дисперсия:

$$s_n^2 = \frac{1}{n-1}\sum_{i=1}^{n} (x_i - \overline{x}_n)^2.$$

СКО:

$$s_n = \sqrt{s_n^2}.$$

Коэффициент вариации:

$$V_n = \frac{s_n}{\overline{x}_n}.$$

ДИ для оценки мат. ожидания:

$$\overline{x}_n \pm z_{\frac{1+\gamma}{2}} \cdot \frac{s_n}{\sqrt{n}},$$

где γ - доверительная вероятность, а $z_{\frac{1+\gamma}{2}}$ - квантиль стандартного нормального распределения.

В расчётах использовались следующие значения квантилей:

$$z_{0,95} = 1,645, \quad z_{0,975} = 1,960, \quad z_{0,995} = 2,576.$$

Им соответствуют доверительные вероятности $0,90$, $0,95$ и $0,99$.

Относительное отклонение каждой характеристики от значения, полученного для полной выборки из 300 элементов, вычислялось по формуле:

$$\delta_{\theta(n)} = \frac{\theta_n - \theta_{300}}{\theta_{300}} \cdot 100\%.$$

Здесь θ_n - значение характеристики для выборки объёма n, а θ_{300} - эталонное значение для полной выборки.

Хар-ка	**Количество случайных величин**						
		10	**20**	**50**	**100**	**200**	**300**
Мат. ож.	Знач.	13,053	10,686	13,879	18,477	15,083	15,228
	%	−14,283	−29,827	−8,859	+21,336	−0,952	
Дов. инт. $(0,90)$	Знач.	±9,288	±4,997	±4,562	±5,663	±3,090	±2,719
	%	+241,596	+83,781	+67,782	+108,275	+13,645	
Дов. инт. $(0,95)$	Знач.	±11,066	±5,954	±5,436	±6,747	±3,681	±3,240
	%	+241,543	+83,765	+67,778	+108,241	+13,611	
Дов. инт. $(0,99)$	Знач.	±14,544	±7,826	±7,144	±8,867	±4,838	±4,258
	%	+241,569	+83,795	+67,778	+108,243	+13,621	
Дисперсия	Знач.	318,772	184,585	384,562	1184,912	705,576	819,695
	%	−61,111	−77,481	−53,085	+44,555	−13,922	
С.к.о.	Знач.	17,854	13,586	19,610	34,423	26,563	28,630
	%	−37,639	−52,546	−31,505	+20,234	−7,220	
К-т вариации	Знач.	1,368	1,271	1,413	1,863	1,761	1,880
	%	−27,234	−32,394	−24,840	−0,904	−6,330	

Таблица 1. Форма 1 – результаты расчета характеристик выборки для различного объема этой выборки и относительное отклонение характеристик от эталонной выборки ($n = 300$)

Вывод:

При увеличении объёма выборки оценки характеристик в целом стабилизируются, а доверительные интервалы сужаются, что говорит о повышении точности оценки математического ожидания. Для полной выборки получены: $\overline{x} = 15,228$, $s_n^2 = 819,695$, $s_n = 28,630$, $V_n = 1,880$.

Отличие среднего для выборок объёмом 200 и 300 значений составляет менее 1%. Коэффициент вариации больше единицы указывает на значительный разброс значений относительно среднего.

Для наглядности уменьшения влияния выбросов я построил график:

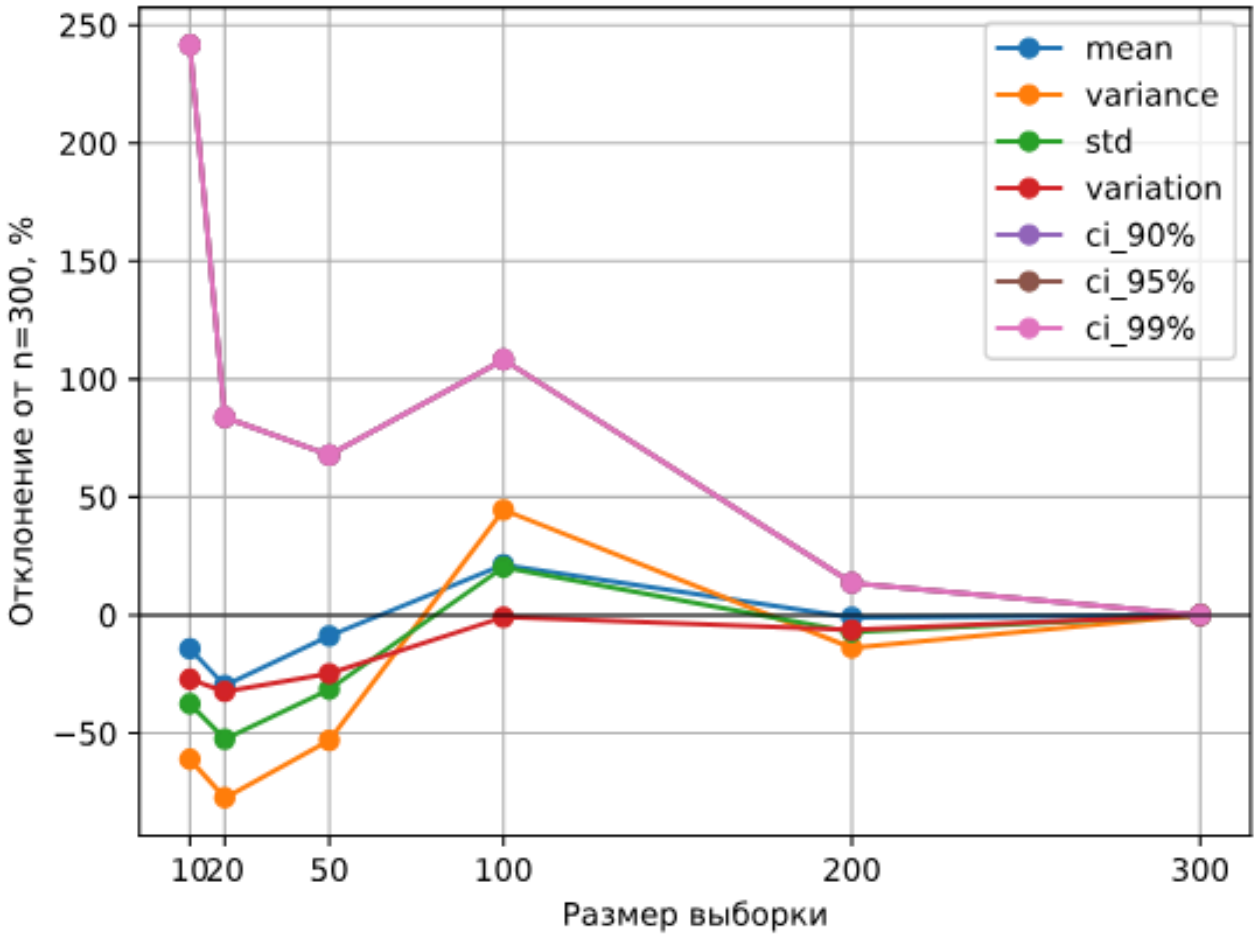


Рис. 1. Зависимость отклонения параметров выборки относительно эталона от размера выборки

2. График значений заданной числовой последовательности

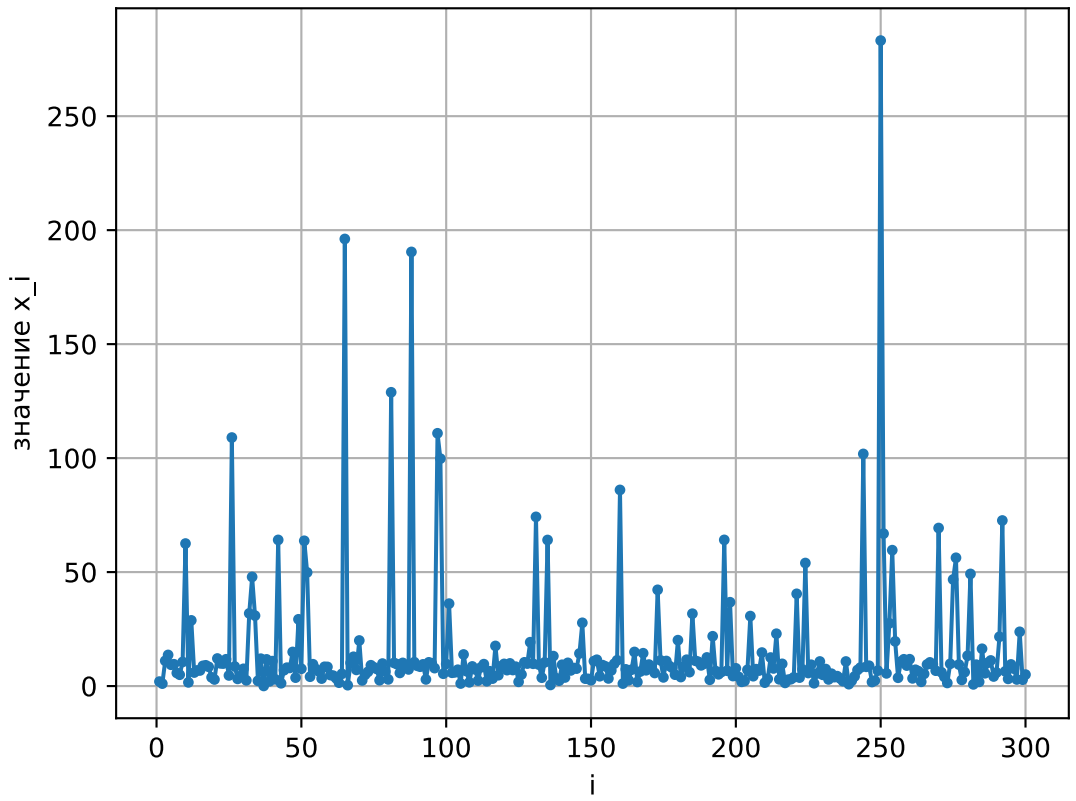


Рис. 2. Значения заданной числовой последовательности

Вывод:

На графике не наблюдается выраженного возрастающего или убывающего тренда, а также явной периодичности.

Большинство значений сосредоточено в нижней части диапазона, однако встречаются отдельные крупные значения, достигающие примерно 285. Это объясняет высокие значения дисперсии, СКО и коэффициента вариации.

Окончательный вывод о её случайности необходимо сделать после автокорреляционного анализа.

3. Автокорреляционный анализ

Автокорреляционный анализ позволяет определить наличие зависимости между элементами числовой последовательности, разделёнными заданным сдвигом k. Для этого исходная последовательность сравнивается с её сдвинутой частью:

$$X_k = (x_{k+1}, x_{k+2}, ..., x_n).$$

В общем виде коэффициент автокорреляции определяется как:

$$r_k = \frac{\operatorname{cov}(X, X_k)}{\sigma_X \sigma_{X_k}}.$$

При $n \gg k$ для его вычисления использовалась приближённая формула:

$$r_k \approx \frac{\sum_{i=1}^{n-k}(x_i - \overline{x})(x_{i+k} - \overline{x})}{\sum_{i=1}^{n}(x_i - \overline{x})^2}.$$

Коэффициенты были рассчитаны для сдвигов от 1 до 10. Полученные значения представлены в таблице и на графике.

Сдвиг ЧП	**1**	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**	**10**
К-т АК для задан. ЧП	0,049	−0,060	−0,034	0,010	−0,038	0,058	0,066	−0,069	0,038	0,024

Таблица 2. Форма 3 – результаты автокорреляционного анализа со сдвигами 1..10

Вывод:

Коэффициенты автокорреляции для сдвигов от 1 до 10 близки к нулю и нерегулярно изменяют знак. Максимальное значение по модулю составляет $0,069$. Выраженная зависимость и признаки периодичности не обнаружены, поэтому исследуемую последовательность можно считать случайной.

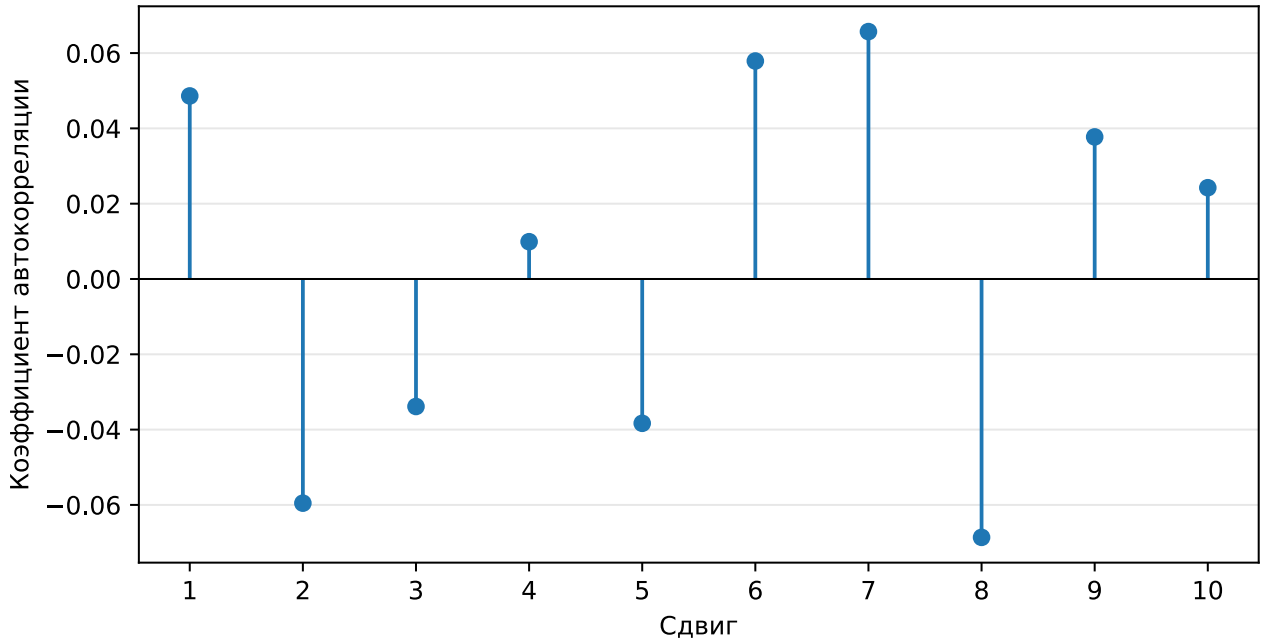


Рис. 3. График коэффициентов автокорреляции для $k \in [1; 10] \cap \mathbb{N}$

4. Гистограмма распределения частот

Количество интервалов гистограммы определялось по правилу квадратного корня:

$$m = \lceil \sqrt{n} \rceil.$$

Для выборки объёмом $n = 300$ получено:

$$m = \lceil \sqrt{300} \rceil = 18.$$

Данное правило было выбрано вместо формулы Стерджеса

$$m = \lceil 1 + \log_2 n \rceil$$

поскольку оно обеспечивает более подробное разбиение диапазона значений и позволяет лучше отобразить основную часть исследуемой последовательности.

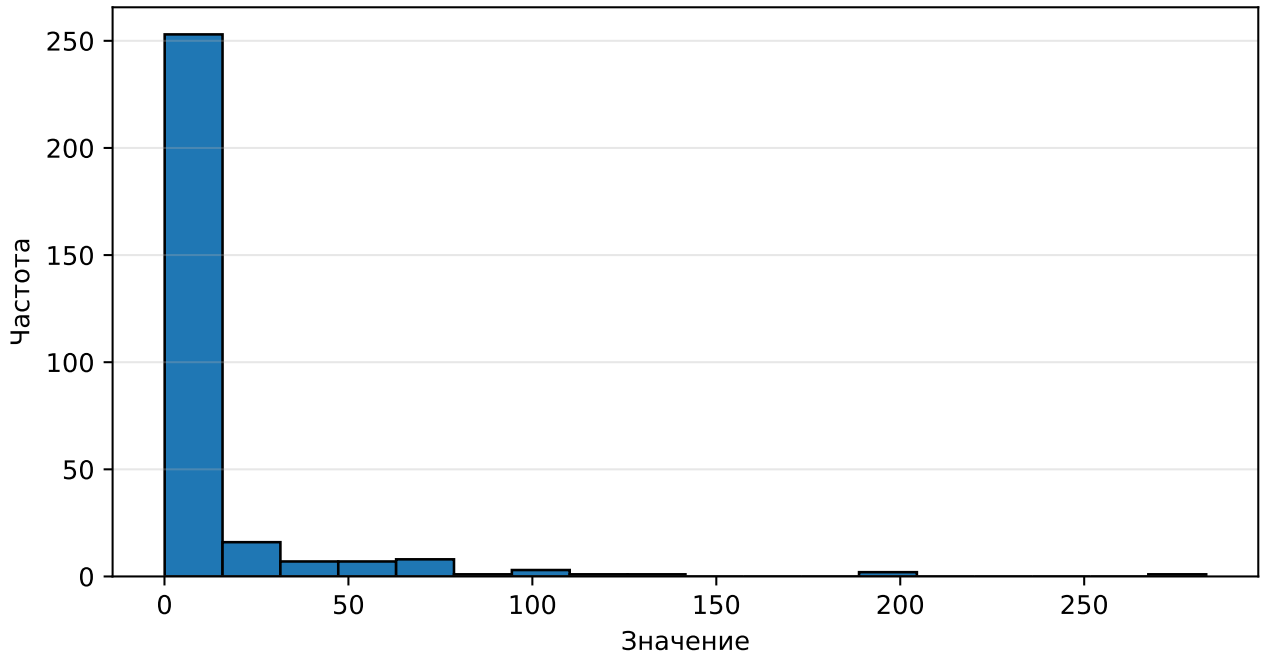


Рис. 4. Гистограмма распределения $m = 18$

Методом зоркого глаза подмечаем, что довольно большая абсолютная разница между первым интервалом и всеми последующими. Можно было бы увеличить частоту разбиения, но это не сильно бы улучшило картину. Поэтому я воспользовался логарифмической шкалой, чтобы визуально «увеличить» значения остальных баров.

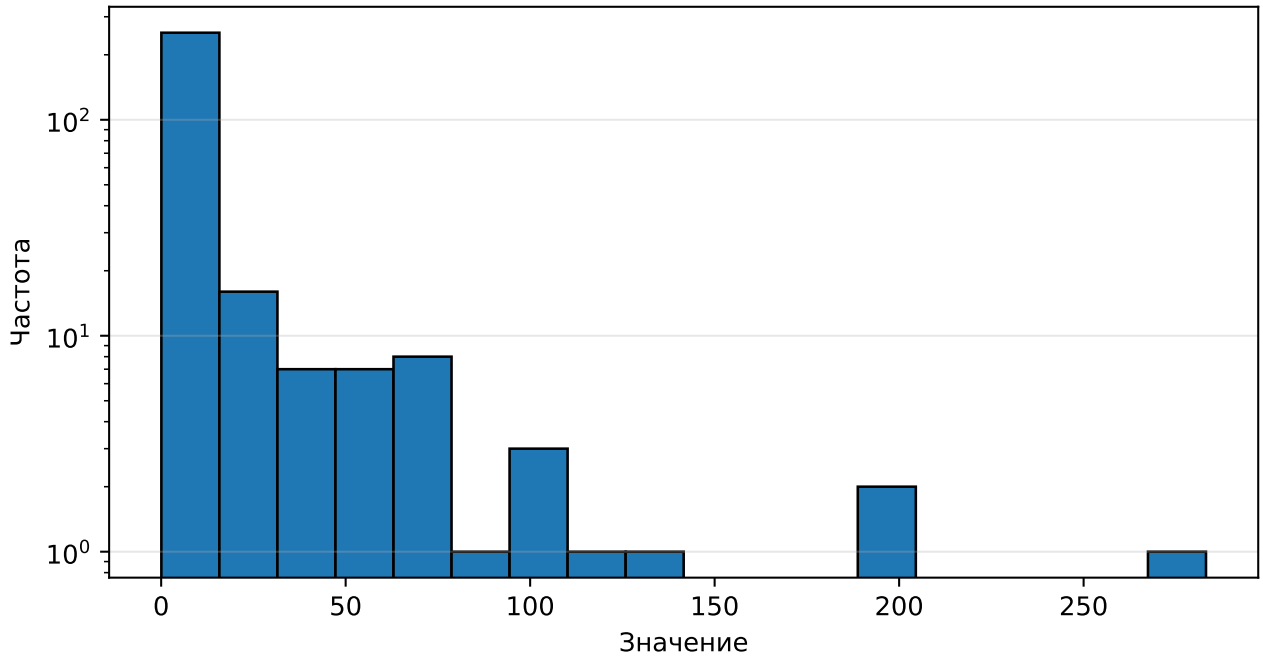


Рис. 5. Логарифмическая гистограмма распределения

Вывод:

Основная часть значений последовательности сосредоточена в области малых значений. При этом наблюдаются редкие значения, достигающие примерно 285, из-за которых формируется длинный правый хвост. Следовательно, распределение является существенно асимметричным и характеризуется большим разбросом.

Это согласуется с полученным коэффициентом вариации $V = 1,880$. Поскольку $V > 1$, в качестве кандидата для дальнейшей аппроксимации следует рассматривать *гиперэкспоненциальное распределение*.

5. Выбор аппроксимирующего закона распределения

Вид аппроксимирующего закона определялся по двум начальным моментам:

$$m_1 = \frac{1}{n}\sum_{i=1}^{n} x_i, \quad m_2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2.$$

Дисперсия, СКО и коэффициент вариации рассчитывались следующим образом:

$$D = m_2 - m_1^2, \quad \sigma = \sqrt{D}, \quad V = \frac{\sigma}{m_1}.$$

В результате расчётов получены значения:

$$m_1 = 15,228, \quad m_2 = 1048,867, \quad D = 816,962, \quad \sigma = 28,583, \quad V = 1,877$$

Поскольку $V > 1$, для аппроксимации выбрано двухфазное **гиперэкспоненциальное распределение** с плотностью:

$$f(x) = p\lambda_1 e^{-\lambda_1 x} + (1-p)\lambda_2 e^{-\lambda_2 x}, \quad x \geq 0.$$

Параметры распределения определялись по формулам:

$$p = \frac{1}{2}\left(1 + \sqrt{\frac{V^2-1}{V^2+1}}\right), \quad \lambda_1 = 2\frac{p}{m_1}, \quad \lambda_2 = 2\frac{1-p}{m_1}.$$

Получены значения $p = 0,873$, $\lambda_1 = 0,11471$ и $\lambda_2 = 0,01662$.

Вывод:

Коэффициент вариации превышает единицу, а гистограмма имеет выраженный правый хвост. Поэтому для аппроксимации исходной последовательности выбран гиперэкспоненциальный закон распределения.

6. Формирование последовательности по аппроксимирующему закону

Для формирования новой последовательности использовалось двухфазное гиперэкспоненциальное распределение с параметрами $p = 0,873$, $\lambda_1 = 0,11471$ и $\lambda_2 = 0,01662$.

Гиперэкспоненциальное распределение является **смесью двух экспоненциальных распределений**. Первая составляющая выбирается с вероятностью p, а вторая - с вероятностью $1 - p$.

Для генерации экспоненциальной случайной величины применялся метод обратного преобразования. Функция экспоненциального распределения имеет вид:

$$F(x) = 1 - e^{-\lambda x}, \quad x \geq 0.$$

Полагая $u = F(x)$, где u - равномерно распределённая случайная величина из интервала $[0; 1)$, получим решив уравнение относительно x:

$$u = 1 - e^{-\lambda x}, \quad x = -\frac{\ln(1-u)}{\lambda}.$$

Алгоритм формирования одного значения последовательности:

1. Сгенерировать независимые равномерные случайные числа u_1 и u_2 из интервала $[0; 1)$.
2. Если $u_1 < p$, выбрать интенсивность $\lambda = \lambda_1$. В противном случае выбрать $\lambda = \lambda_2$.
3. Рассчитать значение СВ по формуле $x = -\frac{\ln(1-u_2)}{\lambda}$.
4. Добавить полученное значение в формируемую последовательность.
5. Повторять действия до получения последовательности из 300 значений.

Вывод:

Был реализован алгоритм формирования последовательности из 300 случайных величин по двухфазному гиперэкспоненциальному закону. Выбор экспоненциальной составляющей выполнялся в соответствии с вероятностью p, а значения генерировались методом обратного преобразования.

7. Сравнение исходной и сгенерированной последовательностей

7.1. Сравнение гистограммы и теоретической плотности

На гистограмму исходной последовательности была наложена плотность двухфазного гиперэкспоненциального распределения. $p = 0.873$, $\lambda_1 = 0.11471$ и $\lambda_2 = 0.01662$.

Вероятность выбора второй экспоненциальной составляющей равна $1 - p = 0.127$.

Общий вид плотности:

$$f(x) = p\lambda_1 e^{-\lambda_1 x} + (1-p)\lambda_2 e^{-\lambda_2 x}, \quad x \geq 0.$$

После подстановки полученных параметров:

$$f(x) = 0.873 \cdot 0.11471 \cdot e^{-0.11471x} + 0.127 \cdot 0.01662 \cdot e^{-0.01662x}, \quad x \geq 0.$$

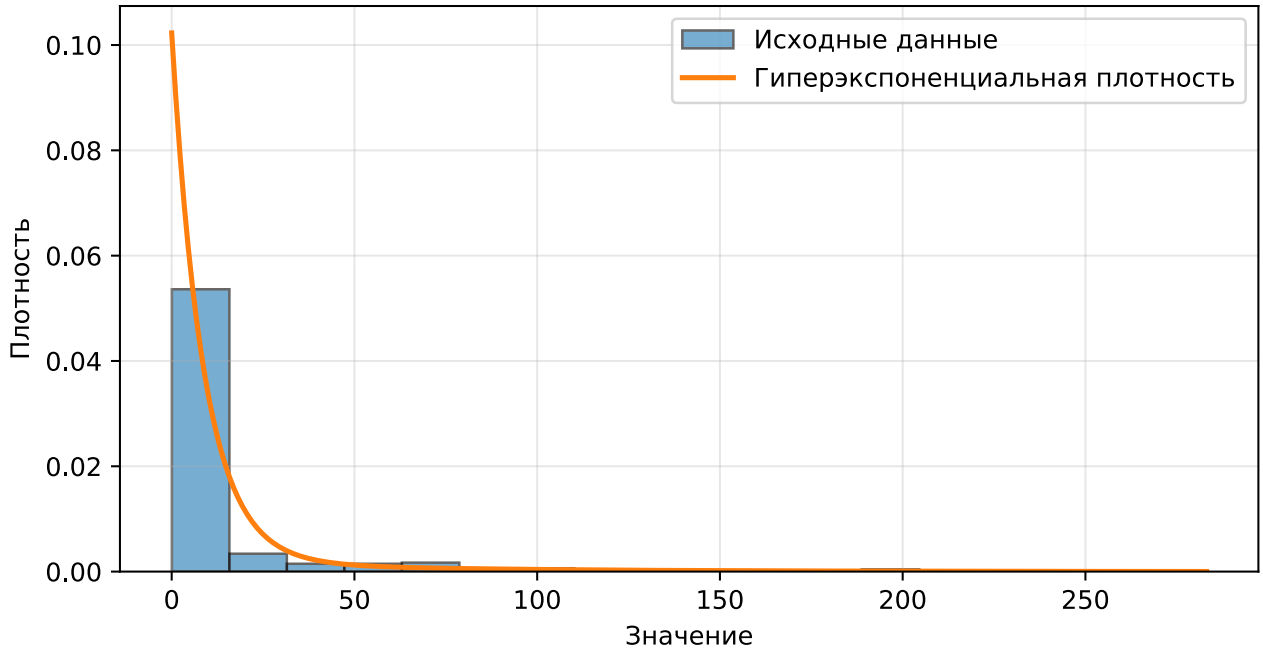


Рис. 6. Сравнение гистограммы исходной последовательности и теоретической плотности

Теоретическая плотность отражает основную форму распределения: большая часть значений сосредоточена около нуля, при этом сохраняется длинный правый хвост. Отличия отдельных столбцов гистограммы от теоретической кривой связаны с ограниченным объёмом выборки и наличием редких выбросов.

7.2. Сравнение числовых характеристик

Относительное отличие характеристик сгенерированной последовательности от характеристик исходной последовательности рассчитывалось по формуле:

$$\delta_\theta = \frac{\theta_{\text{ген}} - \theta_{\text{исх}}}{\theta_{\text{исх}}} \cdot 100\%.$$

Характеристика		Количество случайных величин					
		10	**20**	**50**	**100**	**200**	**300**
Мат. ож.	Знач.	13,589	16,961	12,010	12,785	12,484	13,428
	%	+4,101	+58,722	−13,466	−30,807	−17,228	−11,824
Дисперсия	Знач.	402,552	780,203	365,704	307,298	271,313	494,198
	%	+26,282	+322,680	−4,904	−74,066	−61,547	−39,710
С.к.о.	Знач.	20,064	27,932	19,123	17,530	16,472	22,231
	%	+12,375	+105,592	−2,483	−49,074	−37,990	−22,353
К-т вариации	Знач.	1,476	1,647	1,592	1,371	1,319	1,656
	%	+7,948	+29,530	+12,692	−26,401	−25,083	−11,941

Таблица 3. Форма 2 - характеристики сгенерированной последовательности и их отличия от исходных значений

Для полной сгенерированной выборки математическое ожидание отличается от исходного на $11,824\%$, СКО — на $22,353\%$, коэффициент вариации — на $11,941\%$, а дисперсия — на $39,710\%$. Различия являются заметными, однако не свидетельствуют об ошибке аппроксимации: теоретические моменты подобранного гиперэкспоненциального закона совпадают с моментами исходной последовательности. Отклонения вызваны ограниченным объёмом сгенерированной выборки и высокой чувствительностью дисперсии к редким большим значениям.

Тестовый запуск генератора на большом числе $100'000$ показал, что данные близки к тем, которых мы от него ждем.

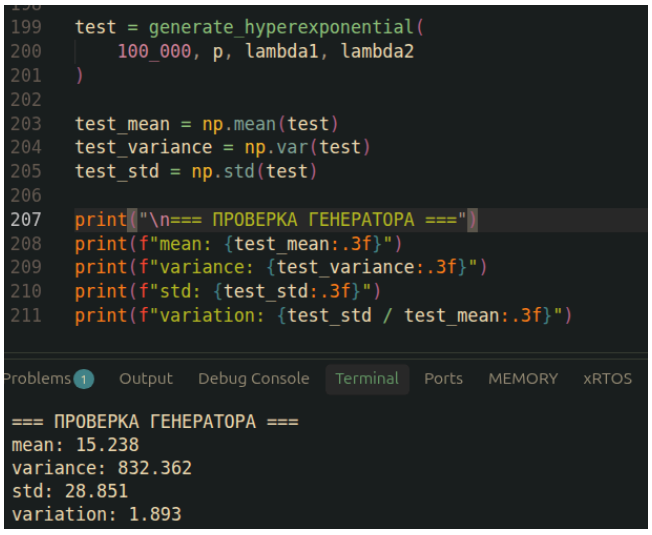


Рис. 7. Тест генератора на большой последовательности

7.3. Сравнение коэффициентов автокорреляции

Сдвиг ЧП	1	2	3	4	5	6	7	8	9	10
Исходная ЧП	0,049	−0,060	−0,034	0,010	−0,038	0,058	0,066	−0,069	0,038	0,024
Сгенерированная ЧП	−0,003	−0,003	−0,004	−0,021	0,026	0,002	−0,068	−0,055	−0,032	0,002

Таблица 4. Форма 3 - коэффициенты автокорреляции исходной и сгенерированной последовательностей

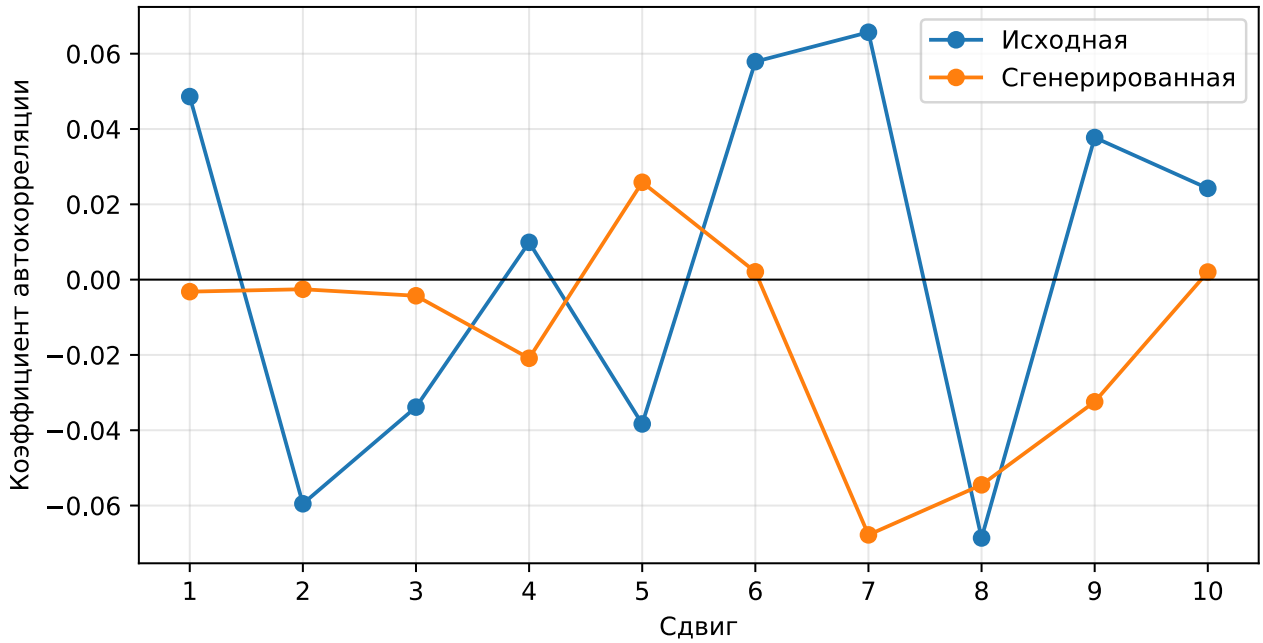


Рис. 8. Сравнение коэффициентов автокорреляции

Коэффициенты автокорреляции обеих последовательностей близки к нулю и нерегулярно изменяют знак. Для сгенерированной последовательности максимальное значение по модулю составляет $0,068$. Таким образом, в ней также не обнаружено выраженной зависимости между соседними элементами или признаков периодичности.

7.4. Корреляционный анализ последовательностей

Коэффициент корреляции между исходной и сгенерированной последовательностями рассчитывался по формуле:

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \overline{x})^2 \sum_{i=1}^{n}(y_i - \overline{y})^2}}.$$

Получено значение:

$$r_{xy} = 0,139.$$

Полученный коэффициент указывает на слабую положительную корреляцию. Следовательно, сильная линейная зависимость между элементами

исходной и сгенерированной последовательностей отсутствует, что ожидаемо для независимо сформированной случайной последовательности.

Вывод:

Гиперэкспоненциальный закон воспроизводит общий характер исходного распределения: концентрацию малых значений, длинный правый хвост и коэффициент вариации больше единицы. Автокорреляция обеих последовательностей близка к нулю, а коэффициент корреляции между ними равен $0,139$, поэтому сильная линейная зависимость отсутствует. При этом в сгенерированной выборке наблюдается заметное отличие дисперсии, обусловленное ограниченным объёмом выборки и высокой чувствительностью этой характеристики к редким большим значениям. В целом полученный закон передаёт основные свойства исходной последовательности.

8. Вывод

В ходе лабораторной работы я вспомнил основные понятия теории вероятностей и матстата: математическое ожидание, дисперсию, СКО, коэффициент вариации, доверительные интервалы и корреляцию.

Теория вероятностей встречается уже третий семестр подряд, но теперь стало понятнее, как все эти формулы применяются к настоящим данным, а не только существуют где-то в конспекте, и как они могут использоваться для генерации собственных случайных последовательностей, подчиняющихся определенному закону.

Я рассчитал характеристики исходной последовательности, посмотрел, как они меняются при увеличении выборки, построил графики и гистограмму, а также провёл впервые в жизни автокорреляционный анализ. Подобрал гиперэкспоненциальный закон распределения и написал программу, которая генерирует по нему новую последовательность.

При сравнении выяснилось, что сгенерированные значения не обязаны идеально совпадать с исходными, даже если закон распределения подобран правильно.